

河南大學

本科毕业论文

(设计)

基于安全边界的近端策略优化路径规划研究

作者姓名: 张华

作者学号: 1710110003

所在学院: 人工智能学院

所学专业: 人工智能(自动化)

导师姓名: XXX

导师职称: XXX

导师单位: 河南大学人工智能学院

2026年4月20日

摘 要

XXXXXXXXXXXXXXXXXXXXXXXXXXXX。

说明用，注意删除！

“摘要”二字为黑体小二号加粗居中，中间空 4 个空格，独立一行，居中，段前段后 1 行；中文摘要内容一般不超过 500 字。内容宋体小四号、1.5 倍行距、首行缩进两字符。摘要正文后下空一行接中文关键词。

关键词：XXXX；XXXX；XXXX；XXXX；XXXX

（说明用，注意删除！“关键词”三字为黑体小四号加粗，无缩进；内容为宋体小四号，各关键词用分号（；）隔开，最后一个关键词后不打标点符号。）

说明（参考用，论文中不要包含此部分，注意删除！）：

中文摘要应具有高度的概括性，语言精炼、明确，扼要叙述论文（设计）的主要内容，包括研究目的与意义、研究内容与方法以及研究结论等，同时需要突出论文（设计）的新论点、新见解或创造性成果。

英文摘要内容应与中文摘要一致，语句通顺，语法正确，准确反映论文（设计）内容。摘要应包括关键词。英文摘要页置于中文摘要页之后正文之前。

关键词是供检索用的主题词条，应采用能覆盖毕业论文（设计）主要内容的通用技术词条（参照相应的技术术语标准），可从标题或正文中选择 3-5 个最能表达主要内容的词语作为关键词，按词条的外延层次排列（外延大的排在前面）。

关键词有中、英文对照，分别附于中、英文摘要后。

ABSTRACT

XXXXXXXXXXXXXXXXXXXXX.

(说明用，注意删除!“ABSTRACT”为 Times New Roman 小二号加粗居中，独立一行;摘要内容为 Times New Roman 小四号、1.5 倍行距、首行缩进两字符。)

Key Words: XXXX,XXXX, XXXX, XXXX,XXXX

(说明用，注意删除!“Key Words”为 Times New Roman 小四号加粗，无缩进，内容为 Times New Roman 小四号，各关键词之间用逗号(,)分开，最后一个关键词后不打标点符号。)

目 录

摘 要.....	I
ABSTRACT	II
第 1 章 绪论	1
1.1 课题背景	1
1.2 国内外在该方向的研究现状及分析	2
1.2.1 国外研究现状	2
1.2.2 国内研究现状	3
1.3 XXXXXXXXXXXXXXXX	5
第 2 章 基于安全场景的自动驾驶环境设计	6
2.1 依赖 LiDAR 的自动驾驶导航理论基础	6
2.1.1 基于 LiDAR 的观测模型	6
2.1.2 坐标系转换与全局环境表征	7
2.1.3 自动驾驶车辆的非完整约束运动学模型	7
2.2 自动驾驶过程中的安全问题数学解释	8
2.2.1 基于奖励塑性的局限性	8
2.2.2 基于约束马尔可夫决策过程理论的安全事件建模	9
2.2.3 安全边界下的几何与运动学描述	10
2.2.4 长期安全约束与拉格朗日对偶优化	10
2.3 基于 MuJoCo 物理引擎和 Safety-Gymnasium 框架的安全场景仿真	11
2.3.1 目标导航场景的建模与现实映射	11
2.3.2 动态避障与多目标场景的建模与现实映射	12
第 3 章 基于拉格朗日安全约束的 PPO 路径规划算法	13
3.1 近端策略优化 PPO 基本流程与网络结构	13
3.1.1 PPO 算法流程与实现原理	13
3.1.2 安全场景下的 Actor 与 Critic 网络结构与更新策略	13
3.2 改进 PPO 算法 PPOLag 的设计与实现	13
3.2.1 拉格朗日乘子代价函数的动态优化过程	13
3.2.2 PPOLag 算法的训练参数与更新流程	13
第 4 章 基于安全边界的路径规划试验结果分析	14
4.1 基础试验配置	14
4.1.1 标准 PPO 试验	14
4.1.2 改进 PPOLag 试验	14
4.1.3 环境迁移试验	14
4.2 试验结果分析	14
4.5.1 路径规划效果分析	14
4.5.2 安全效能提升分析	14
4.5.3 环境迁移分析	14
结 论	15
参考文献	16
致 谢	17

第 1 章 绪论

1.1 课题背景

随着机器人技术与人工智能的飞速发展，自动驾驶汽车、无人机、移动机器人以及人机协作机械臂等自主系统正以前所未有的规模融入人类社会生活。路径规划作为自主系统的核心组件，旨在为系统寻找一条从起始状态到目标状态的冲突规避路径。然而，在复杂的城市仿真、工业协作及动态海事环境中，路径规划面临着安全性、实时性与任务复杂性的多重挑战。

传统路径规划算法如 Dijkstra、A* 及快速搜索随机树（RRT）在静态、完全已知的环境中表现卓越，能有效寻找最短路径或可行解。但这些方法在处理复杂安全状态下的时序逻辑规范时显得捉襟见肘，如通过定时开闭的电梯门等问题。为此，研究者引入了线性时序逻辑等形式化方法，利用模型检测工具将复杂的任务规范转化为机器可执行的规划路径。尽管形式化方法增强了任务表达能力，但在动态障碍物多、计算实时性要求高的场景下，传统的采样或图搜索方法往往面临维数灾难或计算延迟过大的问题。

深度强化学习（Deep Reinforcement Learning），特别是近端策略优化（PPO）算法的出现，为动态环境下的路径规划提供了新思路。通过与环境的试错交互，智能体能够学习到应对不确定性的避障策略。然而，传统的深度强化学习方法通常被视为“黑盒”，其决策过程缺乏透明度，且在训练初期容易产生碰撞等危险行为，这在安全敏感型任务中是不可接受的。

基于安全边界的约束优化成为平衡性能与安全的关键路径。当前研究趋向于为神经网络控制引入显式的安全层或几何约束，如安全框、凸包安全过滤机制。。例如，ISO/TS 15066 标准为协作机器人设定了严格的速度与分离监控（SSM）规则，要求机器人必须根据与人的距离实时调整航迹。此外，行人行为的犹豫性、海事规则的法定约束以及传感器噪声导致的不确定性，都要求路径规划算法不仅能规划出物理上可行的路径，更要在显式的风险感知边界内进行决策更新。

综上所述，开发一种既能处理复杂任务规范，又能在显式安全边界内利用 PPO 算法进行高效学习与快速重规划的系统，对于提升自主系统在非结构化环境中的生存能力与协作效率具有深远的理论意义与应用价值

1.2 国内外在该方向的研究现状及分析

近年来，国内外在利用深度强化学习进行路径规划方面取得了很多研究进展，从算法层面上，基于 Actor-Critic 方法的策略网络优化方法被用来解决路径规划马尔可夫决策问题的动态规划，常见的多以 PPO、DDPG、GRPO 等算法为框架进行动态路径规划。同时，由于强化学习解决路径规划问题是从马尔可夫过程入手，基于不确定性的动作空间导致了高安全边界下模型信任度降低的问题。为了解决这一问题，国内外研究界做出了以下相关研究。

1.2.1 国外研究现状

2005 年，Fainekos 等人在机器人运动规划的形式化表达方面开展了研究，利用时序逻辑（TL）来描述复杂的机器人任务规范，推动了形式化方法与路径规划的结合^[1]。

2015 年，Mnih 等人在通用智能体架构方面开展了研究，通过深度 Q 网络（DQN）在 Atari 游戏上的成功，开启了深度强化学习应用于复杂决策任务的新纪元。同年，Sohn 等人在生成式模型方面开展了研究，提出了条件变分自编码器（CVAE），为学习结构化的输出表征提供了强力工具^[2]。

2017 年，策略梯度作为复杂环境下有效的强化学习工具被引入无人驾驶路径规划方向。Schulman 等人在策略梯度算法的稳定性方面开展了研究，提出了近端策略优化（PPO）算法，通过剪切目标函数解决了训练中参数更新过大的问题，成为 DRL 领域的基准算法^[2]。Kyunghoon Cho 等人在满足协同安全时序逻辑（sc-LTL）的成本感知规划方面开展了研究，结合 RRT* 与交叉熵优化，实现了在逻辑约束下寻找累积成本最低路径的目标^[1, 3]。Ray 等人在安全强化学习的基准测试方面开展了研究，提出了 PPO-Lagrangian 等算法，利用拉格朗日乘子法处理策略优化过程中的显式安全约束^[2]。

在之后，一系列的基于安全的算法结构研究被提出。2020 年，Binyu Wang 等人在动态环境下的可扩展导航方面开展了研究，提出了全局引导强化学习（G2RL）方法，通过 A* 算法生成的全局路径指导局部 RL 智能体，解决了大规模地图中的奖励稀疏问题^[4]。2021 年，L. Zheng 等人在控制仿射系统的安全保障方面开展了研究，提出了顶点策略网络（VPNs），通过计算控制变量在几何凸集顶点上的组合，

确保动作输出严格遵守物理安全限制^[2]。2024 年, Kyoungcho Lee 与 Kyunghoon Cho 在端到端控制合成方面开展了研究, 提出了一种结合 CVAE 候选轨迹生成与 CNN-RNN 轨迹细化的架构, 实现了从任务规范到最优控制序列的直接映射^[5]。

近年来, 随着深度学习框架的持续效能涌现, 基于时序、多头注意力等网络结构也被引入策略网络用于优化控制对象自身的物理特性。2025 年, Sarah Al-Shareeda 等人在犹豫行为下的避障方面开展了研究, 开发了基于 LSTM 增强的 PPO 框架, 使自动驾驶车辆能够根据行人在无信号横道前的随机停留或逆行行为调整规避策略^[6]。Cesare Tonola 等人在人机协作的实时重规划方面开展了研究, 提出了 MARSHA 算法, 结合了反应式路径调整与安全感知代价函数, 有效减少了由于操作员干扰导致的机器人停机时间^[7]。2026 年, Xu Zhao 等人在自动驾驶风险感知决策方面开展了研究, 结合 LSTM 运动预测与动态碰撞时间安全门控, 构建了一个能在突发切入场景下显式执行紧急制动的风险透明智能体^[8]。

1.2.2 国内研究现状

近年来, 国内学者在基于深度强化学习的路径规划领域展开了大量且深入的研究。整体研究脉络呈现出从早期的离散动作空间算法（如 DQN）向连续动作空间算法（如 SAC、PPO）演进的趋势, 并在近两年高度聚焦于“安全性”、“动态避障”以及“端到端”架构的落地^[9]。

针对特定复杂环境下的基础路径规划问题, 国内学者进行了大量的初步探索与算法改进。尹业波等人针对核环境下的高风险与未知特征, 开展了基于改进 DQN 算法的机器人路径规划研究。该研究通过优化强化学习的经验回放机制与奖励函数设计, 有效提升了机器人在高辐射、复杂未知环境中的避障能力和收敛速度^[10]。韦春有和张劲分别针对移动机器人在动态环境和室内复杂环境下的路径规划难题展开研究。韦春有提出了一种结合连续动作空间的深度强化学习框架, 有效解决了传统离散算法在面对动态障碍物时规划效率低下、动作不平滑的问题^[11]。而张劲则重点突破了室内狭窄通道和密集障碍物场景下的导航瓶颈, 通过改进网络结构显著提高了机器人的通行效率^[12]。

针对动态障碍引发的搜索困难问题, 赵子锐等人针对三维空间中的动态障碍物场景研究了无人机的路径规划算法。该研究通过改进强化学习的网络结构, 提升

了无人机对动态威胁的轨迹预测和规避能力，使得无人机能够在高速飞行的同时保持极低的碰撞率^[13]。在自动驾驶领域，聂文鹏等人针对自动驾驶的安全决策问题，构建了包含多种危险场景（如行人横穿、车辆强行并线等）的仿真环境。其研究验证了深度强化学习在处理复杂交通交互时的安全决策能力^[14]。

针对策略网络在线更新的探索优化方面，胡立坤等人提出了一种基于突变定位 SAC（Soft Actor-Critic）算法的移动机器人路径规划方法。该研究通过引入突变定位机制，增强了算法在未知环境中的探索能力，提升了复杂动态环境中的路径规划成功率^[15]。在多传感器融合方面，张慧玉等人创新性地将目标检测算法 YOLO 与 PPO 算法相结合，开展了无人机路径规划研究。该方法利用 YOLO 提供的高精度视觉感知信息，结合 PPO 算法的连续控制优势，实现了无人机在复杂三维空间中的高效避障与目标追踪^[16]。

别桐等人提出了一种基于 Safe-PPO 算法的安全优先路径规划方法。该研究提出了传统奖励塑形的局限，将安全约束直接引入 PPO 算法的优化目标中，在保证路径规划效率的同时，严格控制了碰撞风险，为高安全性要求的自动驾驶场景提供了全新的解决思路^[17]。董澳等人进一步深化了安全强化学习在自动驾驶中的应用，提出了一种基于输入约束和输出映射的安全强化学习算法。从数学层面上保证了智能体输出动作的安全性^[18]。邓明星等人开展了基于规则操作性 PPO 的无人船避碰方法研究，将国际海上避碰规则（COLREGs）等人类先验知识融入 PPO 算法中^[19]。

2025 年，易熙琼等人开展了基于自适应强化学习的智能机器人容错控制研究。该研究针对机器人在执行路径规划任务时可能发生的传感器失效或执行器故障，提出了一种自适应容错控制策略，确保机器人在部分硬件失效的情况下仍能安全、稳定地到达目标点^[20]。在自动驾驶的终极形态探索上，尤国良等人针对复杂城市道路场景，开展了面向自动驾驶的端到端规划算法研究。该研究利用深度强化学习直接将传感器原始数据映射为车辆的底层控制指令，简化了传统自动驾驶系统繁琐的模块化架构，并在复杂的路口多车博弈中展现出超越传统规则算法的优异性能^[21]。

1.3 XXXXXXXXXXXXXXXX

XXXXXXXXXXXXXXXXXX。XXXX 如表 1.1 所示。

表 1-1 表标题

表头			
表文			

第2章 基于安全场景的自动驾驶环境设计

为了解决前文所述探索黑盒与高安全环境的显示约束问题，首先要明确安全事件在强化学习中的定义，进行安全事件建模，本文基于依赖激光雷达（Light Detection and Ranging, LiDAR）的汽车自动驾驶导航为案例进行了路径规划环境的设计与建模。进一步，根据导航环境建模提出了马尔可夫决策过程的动态安全事件模型。最后，在此基础上，通过计算机物理仿真技术构建可用于路径规划强化学习的动态环境，为下一节路径规划算法设计提供仿真环境。

2.1 依赖 LiDAR 的自动驾驶导航理论基础

在现代自动驾驶系统中，环境感知与自主导航是实现车辆智能化的核心前提。相较于基于视觉的端到端自动驾驶方案，基于激光雷达的导航方案因其主动发光、抗环境光干扰能力强、测距精度极高等物理特性，成为了高级别自动驾驶系统中不可或缺的传感器。

2.1.1 基于 LiDAR 的观测模型

LiDAR 的核心工作机制是飞行时间法。传感器通过发射器向周围环境发射高频的近红外激光脉冲，当激光束遇到障碍物表面时发生漫反射，部分反射光被接收器捕获。通过高精度计时器记录激光脉冲从发射到接收的时间差 Δt ，即可计算出传感器与障碍物之间的绝对物理距离。

设光速为 c （约为 $3 \times 10^8 \text{ m/s}$ ），则第 i 束激光测得的径向距离 d_i 的基础数学表达式为：

$$d_i = \frac{c \cdot \Delta t_i}{2} \quad (2-1)$$

在自动驾驶的三维空间中，单线或多线 LiDAR 会通过内部的机械旋转电机或固态相控阵列，以一定的角分辨率 $\Delta\alpha$ （水平方向）和 $\Delta\beta$ （垂直方向）进行全方位扫描。假设 LiDAR 传感器的局部坐标系原点为 O_{sensor} ，某次扫描脉冲的水平方位角为 α_i ，垂直俯仰角为 β_i ，则该反射点在传感器局部三维笛卡尔坐标系下的坐标 $p_i^{sensor} = [x_i, y_i, z_i]^T$ 可由球坐标系转换得到：

$$\begin{pmatrix} x_i \\ y_i \\ z_i \end{pmatrix} = \begin{pmatrix} d_i \cos(\alpha_i) \cos(\beta_i) \\ d_i \cos(\alpha_i) \sin(\beta_i) \\ d_i \sin(\alpha_i) \end{pmatrix} \quad (2-2)$$

在一次完整的扫描周期（如 10Hz 的旋转频率下，周期为 0.1s）内，LiDAR 会收集到海量的三维坐标点，这些点构成的无序集合被称为点云。设一次扫描包含 N 个有效反射点，则点云集合 $\mathcal{P}$ 可表示为：

$$\mathcal{P} = \{p_1^{sensor}, p_2^{sensor}, \dots, p_N^{sensor}\} \in \mathbb{R}^3 \quad (2-3)$$

2.1.2 坐标系转换与全局环境表征

在自动驾驶导航任务中，仅获取传感器坐标系下的点云是不够的。车辆需要知道障碍物在全局地图或车辆本体坐标系下的确切位置，这就需要引入刚体变换的数学模型。

设车辆本体坐标系的原点位于车辆后轴中心，LiDAR 传感器安装在车顶，其相对于车辆本体坐标系的平移向量为 $T_s^v = [t_x, t_y, t_z]^T$ ，旋转矩阵为 $R_s^v \in SO(3)$ 。

则点云中的任意一点 p_i^{sensor} 转换到车辆本体坐标系下的坐标 $p_i^{vehicle}$ 为：

$$p_i^{vehicle} = R_s^v p_i^{sensor} + T_s^v \quad (2-4)$$

进一步地，若已知车辆在全局地图中的实时位姿，即全局坐标 (X_v, Y_v, Z_v) 和航向角 ψ 、俯仰角 θ 、横滚角 ϕ ，则可以构建车辆到全局坐标系的旋转矩阵 R_v^w 和平移向量 T_v^w 。点云在全局坐标系下的绝对坐标 p_i^{world} 为：

$$p_i^{world} = R_v^w p_i^{vehicle} + T_v^w \quad (2-5)$$

通过上述齐次坐标变换，自动驾驶系统能够将瞬时的 LiDAR 扫描数据投影到全局栅格地图中，从而区分出自由空间、占据空间和未知空间，为后续的路径规划算法提供确切的环境表征。

2.1.3 自动驾驶车辆的非完整约束运动学模型

为了在强化学习和路径规划中进行数学抽象，通常采用差速驱动模型。设车辆在二维平面上的状态为 $q = [x, y, \theta]^T$ ，其中 (x, y) 为车辆中心坐标， θ 为车辆的航向角。车辆的控制输入为线速度 v 和角速度 ω 。

在极短的时间步长 Δt 内，车辆的连续时间运动学微分方程可表示为：

$$\begin{pmatrix} \dot{x} \\ \dot{y} \\ \dot{\theta} \end{pmatrix} = \begin{pmatrix} v \cos(\theta) \\ v \sin(\theta) \\ \omega \end{pmatrix} \quad (2-6)$$

在离散时间的马尔可夫决策过程（MDP）中，采用欧拉前向积分对上述微分方程进行离散化，得到时刻 t 到 $t+1$ 的状态转移方程：

$$\begin{pmatrix} x_{t+1} \\ y_{t+1} \\ \theta_{t+1} \end{pmatrix} = \begin{pmatrix} x_t \\ y_t \\ \theta_t \end{pmatrix} + \begin{pmatrix} \dot{x} \\ \dot{y} \\ \dot{\theta} \end{pmatrix} \Delta t \quad (2-7)$$

该运动学模型是自动驾驶导航的基石。路径规划算法输出的动作指令本质上就是对 v_t 和 ω_t 的连续控制。车辆必须在满足上述非完整约束的前提下，利用 LiDAR 数据避开障碍物，并最终使状态 $[x_t, y_t]^T$ 收敛至目标点 $[x_{goal}, y_{goal}]^T$ 。

2.2 自动驾驶过程中的安全问题数学解释

在明确了导航的基础理论后，自动驾驶面临的最大挑战是如何在复杂的动态环境中保证绝对的安全性。传统的路径规划算法通常将障碍物视为不可逾越的绝对边界，但在面对高维连续状态空间和不确定性动态障碍物时，这些方法往往面临局部极小值或计算维度爆炸的问题。近年来，深度强化学习在路径规划中展现出强大的泛化能力。然而，标准强化学习的目标是最大化累积奖励，这导致智能体在训练初期会进行大量危险的“试错”，甚至在收敛后也可能为了追求效率而擦碰障碍物。为了从根本上解决这一问题，必须对“安全”进行显示的数学定义，并引入约束优化理论。

2.2.1 基于奖励塑性的局限性

在早期的自动驾驶强化学习研究中，处理安全问题最直观的方法是奖励塑形。即在标准马尔可夫决策过程 $M = \langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma \rangle$ 中，将碰撞事件作为一个巨大的负向惩罚项直接融入奖励函数 $R(s, a)$ 中。

设到达目标的奖励为 $R_{goal} > 0$ ，发生碰撞的惩罚为 $P_{collision} \ll 0$ ，则综合奖励函数可写为：

$$R(s_t, a_t) = \begin{cases} R_{goal}, & \text{达到目标} \\ P_{collision}, & \text{发生碰撞} \\ -c_{step}, & \text{时间惩罚} \end{cases} \quad (2-8)$$

然而，这种将“任务目标”与“安全约束”耦合在单一标量信号中的做法，在数学上存在致命缺陷：

首先是权重敏感性与奖励作弊：如果 $P_{collision}$ 的绝对值过大，智能体会发现“停在原地不动”虽然得不到 R_{goal} ，但能完美避免 $P_{collision}$ ，从而陷入次优的保守策略；如果 $P_{collision}$ 过小，智能体则会选择“顶着碰撞的惩罚强行冲向目标”，因为只要 $R_{goal} + P_{collision} > 0$ ，这种危险行为在数学期望上就是“合理”的。

其次是单一的期望奖励最大化无法提供任何关于碰撞概率的统计学上限保证，这在对生命财产安全要求极高的自动驾驶领域是不可接受的。

2.2.2 基于约束马尔可夫决策过程理论的安全事件建模

为了解决前文所述的奖励作弊问题，本文引入约束马尔可夫决策过程（Constrained Markov Decision Process, CMDP）作为自动驾驶安全事件模型的底层理论框架。

通过在标准 MDP 的基础上引入独立的代价函数集合构成 CMDP 过程，将安全性与任务目标彻底解耦。一个 CMDP 可以用一个元组定义：

$$\mathcal{M}_{CMDP} = \langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \mathcal{C}, \gamma, \gamma_c \rangle \quad (2-9)$$

其中：

$\mathcal{S}$ 为车辆的状态空间（如前文定义的位姿与 LiDAR 观测）。

$\mathcal{A}$ 为车辆的连续动作空间（线速度与角速度控制）。

$\mathcal{P}: \mathcal{S} \times \mathcal{A} \times \mathcal{S} \rightarrow [0,1]$ 为状态转移概率，由运动学模型和环境物理定律决定。

$\mathcal{R}: \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ 为任务奖励函数，仅负责引导车辆前往目标。

$\mathcal{C}: \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}_{\geq 0}$ 为瞬时代价函数，专门用于量化车辆当前状态的危险程度。

$\gamma \in [0,1)$ 和 $\gamma_c \in [0,1)$ 分别为奖励和代价的折扣因子。

2.2.3 安全边界下的几何与运动学描述

在 CMDP 框架下，瞬时代价函数 $\mathcal{C}(s_t, a_t)$ 是对自动驾驶“安全边界”的直接数学映射。在连续的物理空间中，安全边界通常由车辆的几何轮廓与障碍物的几何轮廓之间的距离函数来定义。

设自动驾驶车辆在二维平面上的刚体碰撞体积占据的空间点集为 $\mathcal{B}_{car}(q_t)$ ，其中 q_t 为车辆当前位姿。设环境中第 k 个障碍物占据的空间点集为 $\mathcal{B}_{obs}^{(k)}$ ，定义车辆与第 k 个障碍物之间的最短欧氏距离函数 D_{min} 为：

$$D_{min}(\mathcal{B}_{car}(q_t), \mathcal{B}_{obs}^{(k)}) = \inf_{p \in \mathcal{B}_{car}(q_t), p' \in \mathcal{B}_{obs}^{(k)}} \|p - p'\|_2 \quad (2-10)$$

基于此距离函数，我们可以严格定义不同级别的安全边界与对应的代价函数。当车辆的物理轮廓与障碍物发生重叠时，即 $D_{min} = 0$ 。此时产生离散的碰撞代价：

$$c_{collision}(s_t) = \begin{cases} 1, & \text{如果 } \exists k, D_{min}(\mathcal{B}_{car}(q_t), \mathcal{B}_{obs}^{(k)}) \leq 0 \\ 0, & \text{否则} \end{cases} \quad (2-11)$$

在实际自动驾驶中，贴着障碍物行驶虽然未发生物理碰撞，但极具危险性。因此，引入安全裕度 $d_{safe} > 0$ 。当距离小于该裕度时，产生连续的风险代价：

$$c_{risk}(s_t) = \begin{cases} \left(\frac{d_{safe} - D_{min}}{d_{safe}} \right)^2, & \text{如果 } 0 < D_{min} < d_{safe} \\ 0, & \text{如果 } D_{min} \geq d_{safe} \end{cases} \quad (2-12)$$

2.2.4 长期安全约束与拉格朗日对偶优化

在定义了瞬时代价 c_t 后，CMDP 要求自动驾驶策略 $\pi_\theta(a | s)$ 不仅要在当前时刻安全，还要保证在未来的整个行驶轨迹中，累积的危险程度处于可控范围内。

定义策略 π_θ 下的期望累积奖励与期望累积代价分别为：

$$J_R(\pi_\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) \right] \quad (2-13)$$

$$J_C(\pi_\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^{\infty} \gamma^t c(s_t, a_t) \right] \quad (2-14)$$

自动驾驶的安全路径规划问题，在数学上被转化为一个带不等式约束的非凸优化问题： $\max_{\theta} J_R(\pi_\theta) \text{ s.t. } J_C(\pi_\theta) \leq d_{limit}$ 。其中， d_{limit} 是人为设定的安全容忍阈值例如，设定 $d_{limit} = 25.0$ ，意味着在整个导航回合中，车辆允许的累积风险代价上限为 25。如果 $J_C(\pi_\theta) \leq d_{limit}$ 严格成立，则我们在数学上证明了该自动驾驶策

略满足预设的安全边界。

为了求解这一带约束的优化问题，强化学习通常引入拉格朗日乘子法，将带约束问题转化为无约束的极小极大博弈问题。其原理如下

构建拉格朗日函数 $L(\theta, \lambda)$: $L(\theta, \lambda) = J_R(\pi_\theta) - \lambda \cdot (J_C(\pi_\theta) - d_{limit})$ 。其中 $\lambda \geq 0$ 为拉格朗日乘子（即安全惩罚系数）。这一数学转化是后续第三章近端策略优化（PPO）算法向其安全约束改进（PPOLag）演进的理论基石。

2.3 基于 MuJoCo 物理引擎和 Safety-Gymnasium 框架的安全场景仿真

本文基于高保真物理引擎 MuJoCo 与 Safety-Gymnasium 框架，将现实中的自动驾驶安全场景抽象为 CarGoal 和 CarButton 两个标准化的仿真环境。具体设计过程如下：

2.3.1 目标导航场景的建模与现实映射

基于 Safety-Gymnasium 设计目标导航场景 CarGoal，它是对自动驾驶中最基础的“非结构化道路点到点导航”任务的深度抽象。在该场景中，差速驱动的车辆被放置在一个被边界墙包围的宽阔平面中，其任务是利用 LiDAR 寻找并安全行驶至随机生成的绿色圆柱体目标区域（Goal）。



图 2-1 CarGoal 场景仿真

为了全面评估算法的安全边界约束能力，CarGoal 场景在环境中注入了三种不同物理特性的危险元素，它们分别映射了现实自动驾驶中的典型威胁：

- (1) 静态危险区域：

静态危险区域代表路面上的水坑、结冰区域、未铺装的泥泞路段或交通禁行区。在仿真中表现为地面上的蓝色二维圆形贴花。车辆驶入该区域不会发生物理碰撞（即速度不会受阻），但会触发安全约束。

(2) 静态易碎障碍物：

静态易碎障碍物代表道路施工摆放的交通锥桶、脆弱的非机动车或路边行人。在仿真中表现为具有实体碰撞体积的青色三维立方体。车辆一旦与其接触，不仅会受到 MuJoCo 引擎的反作用力导致速度骤降，还会推动该物体发生位移。

在 CarGoal 环境中，车辆的最终瞬时代价为上述二者代价的线性叠加。

2.3.2 动态避障与多目标场景的建模与现实映射

在复杂的城市交通中，车辆不仅要避开障碍物，还必须遵守严格的交通规则如红绿灯或在指定的公交站点按顺序停靠，使用 Safety-Gymnasium 设计 CarButton 场景。环境中散布着多个不同颜色的物理按钮（Buttons）。在任意时刻，只有一个按钮被激活，其余按钮处于未激活状态。车辆的任务是精确导航并触碰当前激活的绿色按钮。一旦触碰成功，系统会给予巨大的正向奖励 R_{goal} ，随后该按钮变为未激活，另一个随机按钮被激活。除了保留 CarGoal 中的静态障碍物外，CarButton 还引入了动态障碍物，代表横穿马路的行人、突然变道的其他车辆或不受控的流浪动物，它们具有独立的内部驱动逻辑，会在环境中进行随机游走。



图 2-2 CarButton 场景仿真

第 3 章 基于拉格朗日安全约束的 PPO 路径规划算法

在第 2 章基础上，本文通过引入拉格朗日乘子，对基于约束的马尔可夫过程进行动态优化，改进近端策略优化的强化学习算法，并利用基于拉格朗日安全约束的 PPO 算法 PPOLag 设计了第 2 章两个关键安全场景的算法流程。

3.1 近端策略优化 PPO 基本流程与网络结构

3.1.1 PPO 算法流程与实现原理

XXXXXXXXXXXXXXXXXXXX。

3.1.2 安全场景下的 Actor 与 Critic 网络结构与更新策略

3.2 改进 PPO 算法 PPOLag 的设计与实现

XXXXXXXXXXXXXXXXXXXX。

3.2.1 拉格朗日乘子代价函数的动态优化过程

XXXXXXXXXXXX。

3.2.2 PPOLag 算法的训练参数与更新流程

XXXXXXXXXXXXXXXXXXXX。

第 4 章 基于安全边界的路径规划试验结果分析

XXXXXXXXXXXXXXXXXX。

4.1 基础试验配置

4.1.1 标准 PPO 试验

4.1.2 改进 PPO_{Lag} 试验

4.1.3 环境迁移试验

4.2 试验结果分析

4.5.1 路径规划效果分析

4.5.2 安全效能提升分析

4.5.3 环境迁移分析

结 论

XXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXX。

说明（供参考，论文中不要保留此内容）：经过分析论证与归纳综合，得出正确的学术观点作为结论，必须准确、完整、真实。不是正文中各段的小结的简单重复。

参考文献

XXXXXXXXXXXXXXXXX
XXXXXXXXXXXXXXXXX
XXXXXXXXXXXXXXXXX
XXXXXXXXXXXXXXXXX
XXXXXXXXXXXXXXXXX
XXXXXXXXXXXXXXXXX

致 谢

说明（供参考，论文中不要包含本内容，注意删除！）：

致谢是对在毕业论文（设计）工作中给予各类资助、指导、协助以及提供各种有利条件的单位、指导教师或其他人员表示感谢，语言应实事求是，切忌浮夸之词。

“致谢”二字为黑体小二号加粗居中，中间空 4 个空格，独立一行；内容为宋体小四号、1.5 倍行距、首行缩进两字符。

- [1] K. Cho, J. Suh, C. J. Tomlin, and S. Oh, "Cost-Aware Path Planning Under Co-Safe Temporal Logic Specifications," *IEEE Robotics and Automation Letters*, [J] vol. 2, no. 4, pp. 2308-2315, 2017.
- [2] J. Pan, X. Feng, and H. Yu, "Efficient and safe decision-making in reinforcement learning: One-step anticipatory policy selector with adaptive safety thresholds," *Expert Systems with Applications*, vol. 318, 2026.
- [3] K. Cho, "Learning-Based Path Planning Under Co-Safe Temporal Logic Specifications," *IEEE Access*, vol. 11, pp. 25865-25878, 2023.
- [4] B. Wang, Z. Liu, Q. Li, and A. Prorok, "Mobile Robot Path Planning in Dynamic Environments Through Globally Guided Reinforcement Learning," *IEEE Robotics and Automation Letters*, [J] vol. 5, no. 4, pp. 6932-6939, 2020.
- [5] K. Lee and K. Cho, "Deep Learning-Based Path Planning Under Co-Safe Temporal Logic Specifications," *IEEE Access*, vol. 12, p. 3351893, 2024.
- [6] S. Al-Shareeda *et al.*, "When Pedestrians Hesitate: PPO-Based RL Collision Avoidance in Uncertain Scenarios," in *2025 International Conference on Smart Applications, Communications and Networking*, 2025.
- [7] C. Tonola *et al.*, "Reactive and Safety-Aware Path Replanning for Collaborative Applications," *IEEE Transactions on Automation Science and Engineering*, 2025.
- [8] X. Zhao, Y. Gao, W. Liu, L. Li, S. Zhang, and Z. Wang, "A risk-aware driving agent with Long Short-Term Memory and Time-to-Collision co-decision and multi-modal fusion in urban simulation," *Engineering Applications of Artificial Intelligence*, [J] vol. 173, 2026.
- [9] 黄鑫, "基于深度强化学习的路径规划算法综述," *机器人*, [J] vol. 48, no. 1, 1 2026.
- [10] 尹业波, "基于改进 DQN 算法的核环境机器人路径规划方法研究与应用," [D], 计算机学院, 南华大学, 2024.
- [11] 韦春有, "基于深度强化学习的移动机器人路径规划研究," [D], 电气工程学院, 广西大学, 2025.
- [12] 张劲, "室内复杂环境下移动机器人路径规划算法研究," [D], 机电工程学院, 南华大学, 2024.
- [13] 赵子锐, "面向动态障碍物的无人机路径规划算法研究与应用," [D], 西安工业大学, 西安, 2025.

- [14] 聂文鹏, "基于深度强化学习的自动驾驶安全决策算法研究," [D], 汽车工程学院, 哈尔滨工业大学, 2025.
- [15] 胡立坤, "未知环境下基于突变定位 SAC 算法的移动机器人路径规划," *计算机应用研究*, [J] vol. 42, no. 2, 2025.
- [16] 张慧玉, "基于 YOLO 和 PPO 的无人机路径规划," *计算机与现代化*, [J] no. 4, 2025.
- [17] 别桐, 朱晓庆, 付煜, 李晓理, 阮晓钢, and 王全民, "基于 Safe-PPO 算法的安全优先路径规划方法," *北京航空航天大学学报*, [J] vol. 49, no. 8, pp. 2108-2118, 2023.
- [18] 董澳, "面向自动驾驶的基于输入约束和输出映射的安全强化学习算法研究," [D], 北京交通大学, 2025.
- [19] 邓明星, "基于规则操作性 PPO 的无人船避碰方法研究," *华中科技大学学报(自然科学版)*, [J/OL] 2025.
- [20] 易熙琼, 谢亚兰, and 舒雨锋, "基于自适应强化学习的智能机器人容错控制," *控制工程*, [J] vol. 32, no. 8, 2025.
- [21] 尤国良, "面向自动驾驶的复杂场景端到端规划算法研究," [D], 中国科学技术大学, 2025.